

Análise de artigos de

DISCINFORMÁTICA

com técnicas de PLN

Eduardo Minholi | Janaina Silva | Nuno Miguel  UEM | C. Computação | 2026

INTRODUÇÃO A I.A.

Prof. Dr. Wagner Igarashi

INTRODUÇÃO

➤ O que é bioinformática?

”A bioinformática reúne subáreas da biologia, tecnologia da informação, ciência da computação, matemática e estatística. O objetivo principal é realizar pesquisas e descobertas em biologia, utilizando expertise de outras áreas como meio para atingir este objetivo.” (PPGB – UFPR)

➤ Descrição e modelagem do problema:

A literatura científica em Bioinformática cresce rapidamente, tornando a revisão manual uma tarefa lenta. Artigos em PDF podem estar diagramados de forma não padronizada. O maior desafio do trabalho é a leitura e limpeza dos arquivos para um processamento eficaz.

> Objetivo do trabalho:

Implementar um software capaz de automatizar o pipeline de extração de metadados críticos (Objetivo, Problema, Método e Contribuição) e mapear os resultados em uma ontologia formal de artigos científicos, operando estritamente por algoritmos de regras e heurísticas, sem o uso de modelos de aprendizado de máquina.

ALINHAMENTO

➤ Processamento de Linguagem Natural (PLN):

Técnicas fundamentais para o tratamento do texto bruto, incluindo:

- Tokenização (divisão do texto em palavras)
- Normalização (caixa baixa e remoção de pontuação);
- Filtragem por stop-words (remoção de termos funcionais vazios de sentido técnico).

➤ Modelos de Linguagem Baseados em Regras:

- Uso de N -gramas e Bag-of-Words para contagem de frequências;
- Associados a Expressões Regulares (Regex);
- E Heurísticas de Padrões Linguísticos (ex: buscar "contributes to" para isolar contribuições).

➤ Web Semântica e Ontologias:

Estruturas lógicas que definem classes, propriedades e relacionamentos para representar conhecimento de forma inteligível por computadores (mapeando a estrutura de um artigo científico).

MATERIAIS E MÉTODOS

➤ Linguagem, Ambiente e Bibliotecas

- Linguagem e Ambiente: Código desenvolvido inteiramente em Python, utilizando ambiente de desenvolvimento padronizado para o grupo.
- Bibliotecas Utilizadas:
 - Extração de texto de PDFs: [Indicar a escolhida, ex: PyPDF2 ou python-pdfbox].
 - Pré-processamento e Texto: Funções nativas do Python (string, re para Expressões Regulares) e estruturas para mapeamento de stop-words.

➤ Pipeline de Execução (Fluxo do Sistema):

- Etapa 1: Leitura de PDFs de um diretório → Formatação de layout de colunas → Pré-processamento e filtragem → Identificação dos 10 termos mais citados e extração das referências.
- Etapa 2: Varredura do texto com busca por padrões linguísticos. Extrai Objetivo, Problema, Método e Contribuição.
- Etapa 3: Padronização das saídas das funções em uma estrutura centralizada (JSON) → Serialização dos dados extraídos no formato de ontologia.
- Etapa 4: Análise dos Resultados utilizando-se de bibliotecas e gerando gráficos e diagramas.

DADOS DO EXPERIMENTO

➤ Tema: Bioinformática.

- Base de Dados: IEEE Xplore (coletados por meio do acesso federado CAFE no portal de periódicos da CAPES).
 - Amostra do Experimento: Conjunto composto por 12 artigos científicos em formato PDF, publicados na área de bioinformática
- Submetidos ao pré-processamento;
 - Contagem de frequência de termos (geração da nuvem de palavras geral);
 - Análise de técnicas mais mencionadas;
 - Evolução temporal;
 - Termos de trabalhos futuros.


DEMONS' IRRAÇÃO

ANÁLISE DE DESEMPENHO


➤ Método de Validação

- Curadoria manual feita pela Janaina para estabelecer um gabarito real em arquivos .txt;
 - Foi mapeado o trecho exato de cada um dos quatro indicadores nos artigos de teste.
- Lógica do Script de Avaliação:
 - Confronto automatizado do JSON estruturado (gerado pelo sistema) contra o gabarito manual para mensurar a precisão textual.

ANÁLISE DE DESEMPENHO



ANÁLISE DE DESEMPENHO



CONFLISÕES

➤ Resultados Alcançados

- O sistema provou-se capaz de realizar a triagem em lote de artigos de Bioinformática;
- Foi alcançando o objetivo de ler PDFs complexos e gerar uma base de conhecimento estruturada em ontologia.

Lições do Desenvolvimento:

- A padronização da Etapa 3 em JSON no início do projeto foi crucial para que Etapas 1, 2 e 4 pudessem integrar suas partes de forma modular e paralela.

➤ Limitações e Aprendizados

A proibição de modelos de aprendizado de máquina evidenciou o quanto desafiador é tratar a semântica natural humana apenas com heurísticas estáticas, ressaltando a importância do rigor na construção de expressões regulares para PLN.

BIBLIOGRAFIA

- Periódicos e Artigos: Repositórios e artigos de Bioinformática consultados no IEEE Xplore via portal CAPES/CAFE UEM.
- Documentação de Software: Documentação oficial do ecossistema Python 3 e das bibliotecas de extração e manipulação de arquivos PDF usadas no projeto.
- Materiais Teóricos: Notas de aula e slides da disciplina de Inteligência Artificial II (IIA – DIN/UEM), livros-texto de Processamento de Linguagem Natural e documentações do padrão W3C para modelagem de Ontologias.



END OF LINE